

Regressione e Analisi di serie temporali

Laboratorio di Intelligenza Artificiale

Vincenzo Bonnici

Corso di Laurea Magistrale in Scienze Informatiche

Dipartimento di Scienze Matematiche, Fisiche e Informatiche

Università degli Studi di Parma

2025-2026

Nei problemi di **classificazione** supervisionata ad ogni pattern x_i del training set é associata un'etichetta y_i (classe di appartenenza) Obiettivo del training é l'apprendimento di un **mapping** dallo spazio dei pattern a quello (**discreto**) delle etichette.

Nella **regressione** i valori y_i sono numerici e **continui** (in $\mathbb{R}$) e l'obiettivo del training é l'**apprendimento di una funzione** $f(x) \mapsto y$.

- f è controllata da un insieme di **parametri**. Se la dipendenza dai parametri è lineare (es assenza di elevazioni a potenza dei parametri nella definizione di f) la regressione si definisce **lineare**
- Nella regressione x è detta variabile **indipendente** e y variabile **dipendente**.
- Si assume che la variabile **indipendente** sia **esatta** mentre la variabile **dipendente** sia affetta da **errore** (es imprecisione di misura)

Se la variabile indipendente è uno scalare x (i.e. una sola variabile indipendente), parliamo di **simple linear regression** (retta di regressione).

Dato un training set TS contenente n dati $(x_1, y_1) \dots (x_n, y_n)$ e la seguente dipendenza tra variabile indipendente e dipendente

$$y_i = \alpha + \beta \cdot x_i + \varepsilon_i$$

dove:

- ε_i è l'errore di misura (incognito) del punto x_i
- α, β sono parametri da determinare


Regressione lineare semplice

La soluzione ai **minimi quadrati** (**Least Square**) del problema consiste nel determinare l'equazione della retta

$$f(x) = y = \alpha + \beta \cdot x$$

che minimizza la somma dei quadrati dei residui

$$\alpha^*, \beta^* = \operatorname{argmin}_{\alpha, \beta} \sum_{i=1 \dots n} (f(x) - y_i)^2 = \sum_{i=1 \dots n} \varepsilon_i^2$$



Il precedente problema di minimizzazione può essere facilmente risolto uguagliando a zero le derivate parziali della funzione obiettivo rispetto ai parametri α, β tenendo le cosiddette equazioni normali.

Risolvendo il sistema (due equazioni in due incognite) si ottiene:


$$\beta^* = \frac{\sum_{i=1...n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1...n} (x_i - \bar{x})^2}$$

$$\alpha^* = \bar{y} - \beta^* \bar{x}$$

dove $\bar{x}$ e $\bar{y}$ sono la media degli X_i e y_i rispettivamente.

Necessari almeno due punti x_i altrimenti il denominatore si annulla.


Regressione lineare semplice



Peso	Altezza
72	173
54	159
65	172
58	170
62	165
72	176
60	173
64	179
55	166
46	158
52	158
47	160
55	167
54	166
55	164
49	157
51	165
51	162

Regressione lineare multipla

Se la variabile indipendente è un vettore x (i.e. più variabili indipendenti), parliamo di **multiple linear regression** (esempio iperpiano di regressione).



Regressione lineare multipla

Generalizziamo a iperpiani ($x \in \mathbb{R}^d$).

Per semplicità di trattazione sia X la matrice rettangolare ($n \times (d + 1)$) ottenuta inserendo sulle righe gli n punti del TS, e avendo cura di inserire a destra una colonna con tutti valori 1

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1d} & 1 \\ x_{21} & & x_{2d} & 1 \\ \vdots & \ddots & \vdots & \\ x_{n1} & \cdots & x_{nd} & 1 \end{bmatrix}$$

e siano

$$\begin{array}{|c|} \hline \text{uno scalare per} \\ \text{ogni pattern} \\ \hline \end{array} \rightarrow y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \text{e} \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_{d+1} \end{bmatrix} \leftarrow \begin{array}{|c|} \hline \text{termine noto} \\ \hline \end{array}$$

i vettori costruiti a partire dai valori della variabile indipendente (uno per ogni pattern) e dai $d + 1$ parametri da determinare.

Regressione lineare multipla

Le relazioni tra variabili indipendenti e dipendente possono essere scritte attraverso le equazioni

$$y_i = \sum_{j=1 \dots d+1} x_{ij} \cdot \beta_j \quad \text{per } i = 1 \dots n$$

...
← indici i, j riferiti alla matrice $\mathbf{X}$

o in forma matriciale come


$$\mathbf{y} = \mathbf{X}\beta$$

per $n > (d + 1)$, $\mathbf{X}$ è rettangolare, quindi ho un sistema di equazioni sovradeterminato.

In formato matriciale la funzione obiettivo da minimizzare Least Square può essere scritta come

$$\|\mathbf{y} - \mathbf{X}\beta\|^2$$

Regressione vs fitting geometrico



La regressione lineare least square minimizza le distanze **verticali** dall'iperpiano e non le distanze **euclidee** (cosa semplicemente ottenibile attraverso PCA). Ciò è conseguenza del fatto che le variabili indipendente e dipendente non hanno ruolo simmetrico (la variabile indipendente si considera esatta, mentre quella dipendente affetta da errore). Nota: scambiando le due variabili il risultato cambia. Nel caso di **nuvole di punti geometrici** le coordinate hanno lo stesso ruolo e PCA fitting è preferibile.

RMSE (Root Mean Square Error) è un indicatore di accuratezza di predizione. esso è la radice quadrata del criterio **MSE (Mean Square Error)** $= \frac{1}{N} \sum_{i=1 \dots N} (\hat{y}_i - y_i)^2$ implicito nell'ottimizzazione least square del modello lineare, dove y_i è il valore osservato e $\hat{y}_i$ è il valore predetto. Quindi $\hat{y}_i - y_i$ è l'errore (lo scostamento tra la curva fittata e i valori di input) punto per punto.

Altri modi di valutare l'accuratezza di predizione (non direttamente utilizzabili come loss per modello lineare) sono:

- **MAE** (Mean Absolute Error) = $\frac{1}{N} \sum_{i=1 \dots N} |\hat{y}_i - y_i|$
 - è più robusta di MSE rispetto a outliers (dati non affidabili con ampi scostamenti)
 - mantiene l'unità di misura (es scostamento in metri)
- **MAPE** (Mean Absolute Percentage Error) = $\frac{1}{N} \sum_{i=1 \dots N} \left| \frac{\hat{y}_i - y_i}{y_i} \right|$. E' una variante del MAE dove la penalizzazione dipende dallo scostamento percentuale rispetto alla grandezza dei dati.
- **R^2** (coefficiente di determinazione) = $1 - \frac{\sum_{i=1 \dots N} (y_i - \hat{y}_i)^2}{\sum_{i=1 \dots N} (y_i - \bar{y})^2}$. Indicatore statistico (con valori tra 0 e 1) che indica quanto il modello lineare fitta i dati (ovvero spiega la varianza della variabile dipendente). **Non valido per modelli non lineari.**



Con un semplice accorgimento è possibile continuare ad utilizzare la regressione lineare per approssimare i dati con **curve** e superfici. Nella teoria introdotta infatti l'importante è che la funzione di regressione sia lineare rispetto ai parametri e non rispetto alla variabile indipendente, i cui elementi possono comparire elevati a potenza, combinati tra loro, come argomento di funzioni trascendenti, ecc.

Accuratezza di predizione

Esempio, per $d = 1$ e modello **quadratico** $y = \beta_1 x^2 + \beta_2 x + \beta_3$ scriviamo X come

$$X = \begin{bmatrix} x_1^2 & x_1 & 1 \\ x_2^2 & x_2 & 1 \\ \vdots & \vdots & \vdots \\ x_n^2 & x_n & 1 \end{bmatrix}$$

ottenendo ($d = 2$ a destra)



Nel caso di dipendenza non lineare del modello dai parametri non esiste soluzione least square in forma-chiusa.

Esempio dalla biologia (enzyme-mediated reaction)

$$y = \frac{\beta_1 \cdot x}{\beta_2 + x}$$

Se la dipendenza è nota (come nell'esempio sopra), per la risoluzione si possono applicare tecniche iterative di **ottimizzazione numerica**:

- È possibile utilizzare il classico algoritmo di **Gradient Descent** (metodo del primo ordine che esegue passi in direzione contraria al gradiente)
- L'algoritmo più noto e utilizzato è quello di **Gauss-Newton** (metodo del secondo ordine che richiede stima Hessiana)

Regressione non lineare - dipendenza sconosciuta

Quando la dipendenza tra la variabile indipendente e dipendente non è nota (potrebbe essere lineare o non lineare) il problema può essere approcciato provando e validando sia il modello lineare (baseline) sia modelli non lineari via via più complessi.

Per alcune tecniche di classificazione studiate esiste una variante efficace per problemi di regressione. Casi notevoli (disponibili in scikit learn) sono

- **Random Forest Regressor**
- **Support Vector Regressor** (SVR). L'idea è di invertire la funzione obiettivo invece di richiedere che nella fascia del margine non ricadano sample, vogliamo che in essa ricada il maggior numero di sample del training set
- **Gradient Boosting Regressor**
- anche le **Reti Neurali** addestrate con classico error backpropagation consentono di risolvere efficacemente problemi di regressione

I vantaggi di un modello non lineare sono

- Maggiore **flessibilità** (più gradi di libertà del modello)
- Controllo della **complessità della soluzione** (gradi di libertà del modello, regolarizzazione, ecc)
- Possibilità di utilizzare funzioni loss alternative rispetto a MSE (che è implicita nella risoluzione least square) quali MAE, MAPE, ecc

Il modello lineare risolto ai minimi quadrati è uno stimatore della media condizionata. Significa che la retta di regressione è determinata per approssimare la media dei dati, e quindi l'entità degli **errori di previsione positivi e negativi** è la stessa.

Nel caso in cui si voglia dare un **peso diverso ai positivi e negativi** (es le conseguenze di una sottostima potrebbero essere più gravi di quelle di una sovrastima) si introduce la **regressione ai quantili** (o **percentili**).

- Con percentile **50%** si passa da media a mediana (la metà dei punti nel training set sono sopra la retta di regressione individuata e la metà sono sotto)
- percentile p la retta è individuata in modo da avere il $p\%$ di punti sotto e $1 - (p)\%$ sopra

Nella formulazione si utilizza una loss MAE con penalità diversa per previsioni in eccesso e difetto.

Per problemi di regressione di **piccole-medie dimensioni**

- Il modello **lineare** (rispetto ai parametri) risolto tramite least square (con fattorizzazione SVD) è l'approccio più semplice che costituisce una sorta di **baseline**
- Un modello **non lineare rispetto alla variabile indipendente** (ma lineare rispetto ai parametri) può essere un'ottima seconda scelta perché coniuga semplicità e flessibilità
- Quando sono necessari modelli più potenti, **Random Forest Regressor** rappresenta una valida alternativa
- Se la dipendenza tra variabile dipendente e indipendente è **nota** (ma **non lineare** rispetto ai parametri) l'ottimizzazione numerica con **Gauss-Newton** è la prima scelta

Per problemi di regressione di **grandi dimensioni** (lineari e non) l'approccio iterativo **Gradient Descent** utilizzato in combinazione con **Reti Neurali** è spesso preferibile per motivi di trattabilità numerica e complessità computazionale.


Nell'ambito del **deep learning**, reti neurali addestrate con gradient descent sono state utilizzate con successo per risolvere problemi di regressione di **enormi dimensioni** come la stima della posizione di un oggetto in un'immagine a partire da milioni di esempi (vedi **Faster R-CNN**)

- la variabile indipendente è un'immagine (pixel)
- La variabile dipendente la bounding box dell'oggetto (trattasi in questo caso di un vettore, quindi multivariate multiple regression)

Serie temporali

In statistica descrittiva, una **serie storica** (o **temporale**) si definisce come **un insieme di variabili casuali (stocastiche) ordinate rispetto al tempo**, ed esprime la dinamica di un certo fenomeno nel tempo.

Le serie storiche vengono studiate sia per **interpretare** un fenomeno, individuando componenti di **trend**, di **ciclicità**, di **stagionalità** e/o di **accidentalità**, sia per **prevedere** il suo andamento futuro.



Le serie storiche possono essere di tipo:

- **deterministico**: se i valori della variabile possono essere esattamente determinati sulla base dei valori precedenti;
- **stocastico**: se i valori della variabili possono essere determinati sulla base dei valori precedenti solo in misura parziale.

La maggioranza delle serie storiche è di tipo stocastico e si rivela quindi impossibile elaborare previsioni prive di errore.

L'approccio **classico** all'analisi delle serie storiche assume un modello del tipo: $Y_t = f(t) + u_t$

nel quale il valore del fenomeno al **tempo** t risulta dalla composizione di una sequenza deterministica, $f(t)$, detta parte **sistematica**, e di una successione di variabili aleatorie, detta parte **stocastica**.

La parte deterministica consente di scomporre il processo in **componenti tendenziali**, cicliche e/o stagionali, e la differenza tra i dati teorici del modello deterministico ed i dati osservati è quindi attribuibile ad una componente casuale residuale.

L'approccio **moderno**, invece, ipotizza che la parte sistematica manchi (o sia stata eliminata dai dati) e si focalizza sulla parte stocastica. Si assume che il processo descritto sia stato generato da un processo stocastico descrivibile mediante un **modello probabilistico di tipo parametrico (regressione lineare multipla)**.

I **momenti fondamentali** di una serie storica sono:

- media $\mu_t = EY_t$
- varianza $\sigma_t^2 = E[(Y_t - \mu_t)^2]$
- autocovarianza (la covarianza del processo con se stesso a coppie di punti temporali) $\gamma_{t,s} = E[(Y_t - \mu_t)(Y_s - \mu_s)]$

- Componente tendenziale o **trend**, mostra un andamento crescente, o decrescente o costante con fluttuazione più o meno regolari. I metodi più utilizzati per determinare il trend sono il **metodo dei minimi quadrati** e il **metodo delle medie mobili**.
- Componente **ciclica** impronta all'evento delle fluttuazioni periodiche o non periodiche attorno alla curva del trend, in momenti di quattro fasi definiti nel ciclo economico (componenti congiunturali) con durata pluriennale:
 - **prosperità**: aumento maggiore dell'aumento dell'anno precedente;
 - **recessione**: aumento minore dell'aumento dell'anno precedente;
 - **crisi**: aumento negativo maggiore dell'anno precedente;
 - **ripresa**: aumento negativo minore dell'anno precedente.

- Componente **stagionale** che determina variazioni che avvengono negli stessi mesi in anni successivi. Questi movimenti vengono analizzati con il metodo della serie ideale di 12 mesi e il metodo della media mobile di 12 mesi.
- Componente casuale o **accidentale**, piccole oscillazioni dovute ad eventi casuali (scioperi, elezioni, fatti importanti).
- Componente occasionale, **raro**, dovuto a eventi bellici, importanti innovazioni tecnologiche, crisi politiche etc. Se tale movimento si smorza rapidamente e non produce variazioni al trend, quel dato statistico viene escluso e sostituito da un dato "fittizio" ottenuto tramite **interpolazione**. Se invece il trend rimane cambiato, si spezzano la serie in due parti e si analizzano separatamente le due parti, dette **periodi osservazionali**.

Componenti delle serie temporali e caratteristiche ad esse associate:

- **Trend**: in cui non esiste un intervallo fisso e qualsiasi divergenza all'interno del set di dati fornito è una linea temporale continua. La tendenza sarebbe Negativa o Positiva o Tendenza Nulla.
- **Stagionalità**: in cui l'intervallo regolare o fisso si sposta all'interno del set di dati in una sequenza temporale continua. Sarebbe curva a campana o dente di sega.
- **Ciclico**: in cui non c'è intervallo fisso, incertezza nel movimento e il suo andamento
- **Irregolarità**: situazioni/eventi/scenari imprevisti e picchi in un breve lasso di tempo.

Analisi di serie temporali

Componenti delle serie temporali e caratteristiche ad esse associate:

	Trend	Seasonality	Cyclical	Irregularity
Time	Fixed Time Interval	Fixed Time Interval	Not Fixed Time Interval	Not Fixed Time Interval
Duration	Long and Short Term	Short Term	Long and Short Term	Regular/Irregular
Visualization				
Nature - I	Gradual	Swings between Up or Down	Repeating Up and Down	Errored or High Fluctuation
Nature - II	Upward/Down Trend	Pattern repeatable	No fixed period	Short and Not repeatable
Prediction Capability	Predictable	Predictable	Challenging	Challenging
Market Model				Highly random/Unforeseen Events – along with white noise.

Obiettivi della analisi di serie temporali:

- capire come funzionano le serie temporali, quali **fattori** influenzano una o più variabili in momenti diversi.
- fornirà le **conseguenze** e le informazioni dettagliate sulle caratteristiche del set di dati fornito che cambia nel tempo.
- supporto per derivare la **previsione** dei valori futuri della variabile delle serie temporali.
- **Presupposti**: esiste una unica ipotesi **stazionaria**, il che significa che l'origine del tempo non influisce sulle proprietà del processo sotto il fattore statistico.

Passi principali della analisi di serie temporali:

- raccolta e pulitura dei dati
- preparazione della visualizzazione rispetto al tempo e rispetto della caratteristica chiave
- osservazione e analisi della stazionarietà della serie
- sviluppo di grafici per comprenderne la natura
- costruzione di modelli – AR, MA, ARMA e ARIMA
- estrazione di nuova conoscenza dalla previsione

Un **processo stazionario** è un processo stocastico la cui distribuzione di probabilità congiunta non cambia se viene traslata nel tempo. Di conseguenza, parametri quali la media e la varianza, se sono presenti, pure non cambiano nel tempo.





Un set di dati stazionario dovrebbe seguire le regole

- Il loro **valore medio** dovrebbe essere completamente **costante** nei dati durante l'analisi
- La **varianza** dovrebbe essere costante rispetto all'orizzonte temporale
- La COVARIANZA misura la relazione tra due variabili.

La causa più comune di violazione della stazionarietà sono le tendenze in media.

Poiché la stazionarietà è un presupposto di fondo, i dati non stazionari sono spesso trasformati per diventare stazionari.

Analisi di serie temporali

	MEAN	Variance	Covariance
Stationary 	 Mean is constant with time Stationary Data	 Variance is constant with time	 Mean value and difference between two spreads is time-independent
Non-Stationary 	 Mean is increasing with time Non-Stationary Data	 Variance is varying with time	 As time increases, the spreads get closer

Verificare la stazionarietà tramite **controlli statistici**


- Augmented Dickey-Fuller (ADF) Test: con ipotesi nulla che la serie sia non-stazionaria e ipotesi alternativa che la serie sia stazionaria.
- Kwiatkowski–Phillips–Schmidt–Shin (KPSS): per testare un'ipotesi nulla che percepirà le serie temporali, come stazionarie attorno a un trend deterministico rispetto all'alternativa di una radice unitaria.

Analisi di serie temporali

Convertire da non-stazionario a stazionario, tre metodi

- detrending
- differencing
- transformation


Detrending: Implica la rimozione degli effetti di tendenza dal set di dati fornito e la visualizzazione solo delle differenze di valori rispetto alla tendenza. Permette sempre di identificare gli schemi ciclici.




Analisi di serie temporali

Differencing: trasformazione della serie in una nuova serie temporale, che usiamo per rimuovere la dipendenza della serie dal tempo e stabilizzare la media delle serie temporali, in modo che la tendenza e la stagionalità vengano ridotte durante questa trasformazione.

$$Y_t = Y_t - Y_{t-1}$$



Transformation: include tre diversi metodi: Power Transform, Square Root e Log Transfer., quello più comunemente usato è Log Transfer.



Metodologia **Moving Average (MA)** (media mobile) anche detta **Rolling Mean**.

Il metodo comunemente utilizzato per le serie temporali è efficace con variazioni casuali a breve termine.

Relativamente associato alle componenti delle serie temporali.

La media mobile è calcolata prendendo la media dei dati delle serie temporali, entro k periodi.


Tre tipi:

- Simple Moving Average (SMA)
- Cumulative Moving Average (CMA)
- Exponential Moving Average (EMA)

Simple Moving Average (SMA)

La SMA è la media non ponderata dei precedenti M punti. La selezione dei punti dati della finestra scorrevole, a seconda della quantità di smussamento, è preferita poiché aumentando il valore di M , si migliora l'attenuazione a scapito dell'accuratezza.

$$SMA_t = \frac{x_t + x_{t-1} + \cdots + x_{M-(t-1)}}{M}$$




Pandas fornisce già degli strumenti per l'analisi di serie temporali. In questo caso `pandas.DataFrame.rolling.mean()`

Cumulative Moving Average (CMA)

Il CMA è la media non ponderata dei valori passati, fino all'ora corrente.

$$CMA_t = \frac{x_1 + x_2 + \dots + x_t}{t}$$




In questo caso `pandas.DataFrame.expanding.mean()`

Exponential Moving Average (EMA) viene utilizzato principalmente per identificare le tendenze e per filtrare il rumore. Il peso degli elementi diminuisce gradualmente nel tempo. Ciò significa che dà peso ai punti dati recenti, non a quelli storici. Rispetto a SMA, l'EMA è più veloce da cambiare e più sensibile.

$$EMA_t = \begin{cases} x_0 & \text{se } t = 0, \\ \alpha x_t + (1 - \alpha)EMA_{t-1} & \text{se } t > 0. \end{cases}$$

dove α è un fattore di smoothing, con valore tra 0 e 1, che rappresenta il peso applicato al periodo più recente.

Exponential Moving Average (EMA)




In questo caso `pandas.DataFrame.ewm.mean()`

Auto-correlation function (ACF) viene utilizzato per indicare e quanto è simile un valore all'interno di una determinata serie temporale e il valore precedente.

Misura il grado di somiglianza tra una data serie temporale e la versione ritardata di quella serie temporale a diversi intervalli che abbiamo osservato. Viene utilizzato per identificare una serie di tendenze nel set di dati fornito e l'influenza dei precedenti valori osservati sui valori attualmente osservati.





La libreria statsmodels ne fornisce una implementazione **statsmodels.tsa.stattools.acf** e **statsmodels.graphics.tsaplots.plot_acf** per graficare.

Partial Auto-Correlation (PACF) è simile alla funzione di correlazione automatica ed è un po' difficile da capire. Mostra sempre la correlazione della sequenza con se stessa con un certo numero di unità di tempo per ordine di sequenza in cui è stato mostrato solo l'effetto diretto e tutti gli altri effetti intermedi sono rimossi dalla serie temporale data.



La temperatura precedente influenza la temperatura attuale, ma il significato di tale influenza diminuisce e aumenta leggermente rispetto alla visualizzazione di cui sopra insieme alla temperatura con intervalli di tempo regolari.

Analisi di serie temporali - scelta di un modello ML



ACF

Plot declines
gradually

Plot drops
instantly

Plot decline
gradually

Plot drop
instantly

PACF

Plot drops
instantly

Plot declines
gradually

Plot Decline
gradually

Plot drop
instantly

Perfect ML -Model

Auto Regressive model.

Moving Average model

ARMA

You wouldn't perform
any model

Ricordarsi che sia ACF che PACF richiedono serie temporali stazionarie per l'analisi.

Auto-regressive model (AR) (modello auto-regressivo) è un modello semplice, che prevede la performance futura in base alla performance passata. Utilizzato principalmente per la previsione, quando esiste una correlazione tra i valori in una determinata serie temporale e i valori che precedono e si succedono (avanti e indietro).

Un modello AR è un modello di regressione lineare, che utilizza variabili ritardate come input.

$$Y_t = C + b_1 Y_{t-1} + b_2 Y_{t-2} + \dots + b_p Y_{t-p} + Er_t$$

Y_t è definita in funzione dei diversi valori passati, dove p sono i valori passati, C è l'intercetta e Er_t sono gli errori al tempo corrente.

Il modello di regressione lineare può essere facilmente costruito utilizzando la libreria scikit-learn indicando l'input da utilizzare. La libreria statsmodels viene utilizzata per fornire funzioni specifiche del modello di autoregressione in cui è necessario specificare un valore di ritardo appropriato e addestrare il modello.

ARMA è una combinazione del modello Auto-Regressivo e Media Mobile per la previsione. Questo modello fornisce un processo stocastico debolmente stazionario in termini di due polinomi, uno per l'Auto-Regressivo e il secondo per la Media Mobile.


$$Y_t = \underbrace{\mu + \sum_{i=1}^q \gamma_i Y_{t-i}}_{\text{Auto-Regressive}} + \underbrace{\varepsilon_t + \sum_{i=1}^q \theta_i \varepsilon_{t-i}}_{\text{Moving Average}}$$

ARMA è il migliore per prevedere le serie stazionarie ma non è adatto alle serie non stazionarie. Quindi è arrivato **AR-I-MA** poiché supporta sia stazionario che non stazionario.


- AR - Usa i valori passati per prevedere il futuro
- MA - Utilizza i termini dell'errore passato nella serie data per prevedere il futuro
- I - utilizza la differenziazione dell'osservazione e rende i dati stazionari

In python **statsmodels.tsa.arima_model**

Analisi di serie temporali - ML




Timeseries Analysis – Process flow



Recurrent Neural Networks (RNN) è l'architettura più tradizionale e accettata, adatta per problemi basati sulla previsione di serie temporali.

RNN è organizzato in livelli successivi e suddiviso in Input, Output e Nascosto (intermedio).

Ogni strato ha lo stesso peso e ogni neurone deve essere assegnato a intervalli temporali fissi. E ricorda che ognuno di essi è completamente connesso con un livello nascosto (Input e Output) con gli stessi passaggi temporali e i livelli nascosti vengono inoltrati e dipendono dal tempo nella direzione.



Componenti della RNN:

- **Input:** Il vettore della funzione di $x(t)$ è l'input, al passo temporale t .
- **Nascosto:** Il vettore della funzione $h(t)$ è lo stato nascosto all'istante t , E' una sorta di memoria della rete stabilita; E' calcolato in base all'input corrente $x(t)$ e allo stato nascosto $h(t - 1)$ del passo temporale precedente:
- **Output:** Il vettore della funzione $y(t)$ è l'output, al passo temporale t .
- **Pesi:** il vettore di input è connesso ai neuroni dello strato nascosto all'istante t tramite una matrice di peso di U . Internamente la matrice di peso W è formata dai neuroni dello strato nascosto del tempo $t - 1$ e $t + 1$, seguito dallo strato nascosto con il vettore di output $y(t)$ di tempo t da una matrice di peso V ; tutte le matrici di peso U , W e V sono costanti per ogni passo temporale.

Vantaggi

- Ha la caratteristica speciale di ricordare ogni informazione, quindi RNN è molto utile per la previsione delle serie temporali.
- Perfetto per creare modelli complessi dal set di dati di serie temporali di input.
- Veloce nella previsione
- Non influenzato da valori mancanti, quindi il processo di pulizia può essere limitato

Svantaggi

- La grande sfida è durante il periodo di addestramento.
- Calcolo costoso